

# 3. Feladat

December 4, 2024

## 0 Előkészületek

### 0.1 Szükséges könyvtárak importálása

```
%reset -f
import pandas as pd
import numpy as np
import statsmodels.api as sm
import matplotlib.pyplot as plt
from sklearn.metrics import mean_squared_error, mean_absolute_error, r2_score
from scipy import stats
from statsmodels.tsa.holtwinters import SimpleExpSmoothing
from statsmodels.graphics.tsaplots import plot_acf, plot_pacf
from statsmodels.tsa.stattools import adfuller
from statsmodels.tsa.arima.model import ARIMA
from statsmodels.stats.diagnostic import acorr_ljungbox
from statsmodels.graphics.gofplots import qqplot
```

### 0.2 Adatok beolvasása

```
# Oszlopok definiálása
cols = ['Idő', 'Érték']

# Adatok beolvasása string-ként
with open('data/bead3.csv', 'r', encoding='latin-1') as file:
    lines = file.readlines()

# Az első sor elhagyása és értékek átalakítása
data = [list(map(float, line.strip().strip('"').split(','))) for line in lines[1:
↪]]

# DataFrame létrehozása
df = pd.DataFrame(data, columns=cols)
```

# 1 Determinisztikus modell illesztése

## 1.1 Kód és eredmények

```
# Modellek összehasonlítása
max_degree = 10
selected_degree = 3 # a kiválasztott fokszám
results = []

# Különböző fokszámú modellek összehasonlítása
for degree in range(0, max_degree):
    X = np.vander(df['Idő'], degree + 1)
    model = sm.OLS(df['Érték'], X).fit()
    r2 = r2_score(df['Érték'], model.fittedvalues)

    results.append({
        'Fokszám': degree,
        'R2': r2,
        'AIC': model.aic,
        'BIC': model.bic
    })

# Eredmények kiírása
results_df = pd.DataFrame(results)
print("\nModellek összehasonlítása:")
print(results_df)

# Kiválasztott fokszámú polinom illesztése
X = np.vander(df['Idő'], selected_degree + 1)
model = sm.OLS(df['Érték'], X).fit()

# Eredmények kiírása
print(f"\n{selected_degree}. fokú polinom illesztése:")
print(model.summary().tables[0])
print(model.summary().tables[1])

# Reziduálisok vizsgálata
residuals = model.resid

# 1. Várható érték vizsgálata
resid_mean = np.mean(residuals)
resid_std = np.std(residuals, ddof=selected_degree+1)
t_stat = resid_mean / (resid_std/np.sqrt(len(residuals)))
p_value_mean = 2 * stats.t.cdf(-abs(t_stat), len(residuals)-1)

# 2. Normalitás vizsgálata (Shapiro-Wilk teszt)
shapiro_stat, shapiro_p = stats.shapiro(residuals)
```

```

# 3. Függetlenség vizsgálata (Ljung-Box teszt)
lb_stat = sm.stats.diagnostic.acorr_ljungbox(residuals)

# 4. Homoszkedaszticitás vizsgálata (Breusch-Pagan teszt)
bp_test = sm.stats.diagnostic.het_breuschpagan(residuals, model.model.exog)

print("\nHibatagok vizsgálata - eredmények:")
print("-" * 50)
print(f"1. Várható érték vizsgálata:")
print(f"Átlag (várható érték becslése): {resid_mean:.6f}")
print(f"t-statisztika: {t_stat}")
print(f"p-érték: {p_value_mean}")

print(f"\n2. Normalitás vizsgálata (Shapiro-Wilk):")
print(f"Teszt statisztika: {shapiro_stat:.6f}")
print(f"p-érték: {shapiro_p:.6f}")

print(f"\n3. Függetlenség vizsgálata (Ljung-Box):")
print("Lag Teszt statisztika p-érték")
print("-" * 35)
for lag, row in lb_stat.iterrows():
    print(f"{lag:2d}    {row['lb_stat']:14.6f}    {row['lb_pvalue']:.6e}")

print(f"\n4. Homoszkedaszticitás vizsgálata (Breusch-Pagan):")
print(f"Teszt statisztika: {bp_test[0]:.6f}")
print(f"p-érték: {bp_test[1]:.6f}")

# Előrejelzés a következő 10 időpontra
future_points = np.arange(len(df) + 1, len(df) + 11)
X_future = np.vander(future_points, selected_degree + 1)
predictions = model.predict(X_future)

print("\nElőrejelzések:")
for i, pred in enumerate(predictions):
    print(f"{future_points[i]}. időpont: {pred:.2f}")

# Ábrázolás
plt.figure(figsize=(12, 6))
plt.scatter(df['Idő'], df['Érték'], color='blue', label='Tényleges értékek')
plt.plot(df['Idő'], model.fittedvalues, color='red', label='Illesztett görbe')
plt.plot(future_points, predictions, color='green', linestyle='--',
        label='Előrejelzés')
plt.xlabel('Idő')
plt.ylabel('Érték')
plt.title(f'{selected_degree}. fokú polinom illesztése és előrejelzés')
plt.legend()

```

```
plt.grid(True)
plt.show()
```

Modellek összehasonlítása:

	Fokszám	R <sup>2</sup>	AIC	BIC
0	0	0.000000	387.062930	388.974953
1	1	0.062344	385.844343	389.668389
2	2	0.902997	274.412442	280.148511
3	3	0.921054	266.113215	273.761307
4	4	0.986175	180.999703	190.559818
5	5	0.987419	178.285939	189.758077
6	6	0.988357	176.408735	189.792896
7	7	0.988364	178.381243	193.677427
8	8	0.994452	143.342890	160.551097
9	9	0.992497	156.440981	171.737165

3. fokú polinom illesztése:

#### OLS Regression Results

```
=====
Dep. Variable:          Érték      R-squared:          0.921
Model:                  OLS        Adj. R-squared:      0.916
Method:                 Least Squares   F-statistic:        178.9
Date:                  Wed, 04 Dec 2024   Prob (F-statistic):  2.30e-25
Time:                  20:18:41      Log-Likelihood:     -129.06
No. Observations:      50          AIC:                266.1
Df Residuals:          46          BIC:                273.8
Df Model:               3
Covariance Type:       nonrobust
=====
```

```
=====
              coef      std err          t      P>|t|      [0.025      0.975]
-----
x1              0.0006      0.000        3.244      0.002        0.000        0.001
x2              0.0064      0.016         0.412      0.682       -0.025        0.038
x3             -2.0320      0.342       -5.935      0.000       -2.721       -1.343
const           9.5845      2.036         4.707      0.000         5.486       13.683
=====
```

Hibatagok vizsgálata - eredmények:

1. Várható érték vizsgálata:

Átlag (várható érték becslése): 0.000000

t-statisztika: 3.9543447227832004e-13

p-érték: 0.9999999999999686

2. Normalitás vizsgálata (Shapiro-Wilk):

Teszt statisztika: 0.971069

p-érték: 0.255692

3. Függetlenség vizsgálata (Ljung-Box):

Lag    Teszt statisztika    p-érték

Lag	Teszt statisztika	p-érték
1	36.706257	1.373379e-09
2	57.588516	3.124732e-13
3	66.733136	2.135808e-14
4	68.558895	4.572428e-14
5	68.644769	1.961309e-13
6	70.969881	2.585887e-13
7	75.831668	9.719502e-14
8	83.001311	1.214121e-14
9	92.734283	4.596171e-16
10	102.056297	2.110987e-17

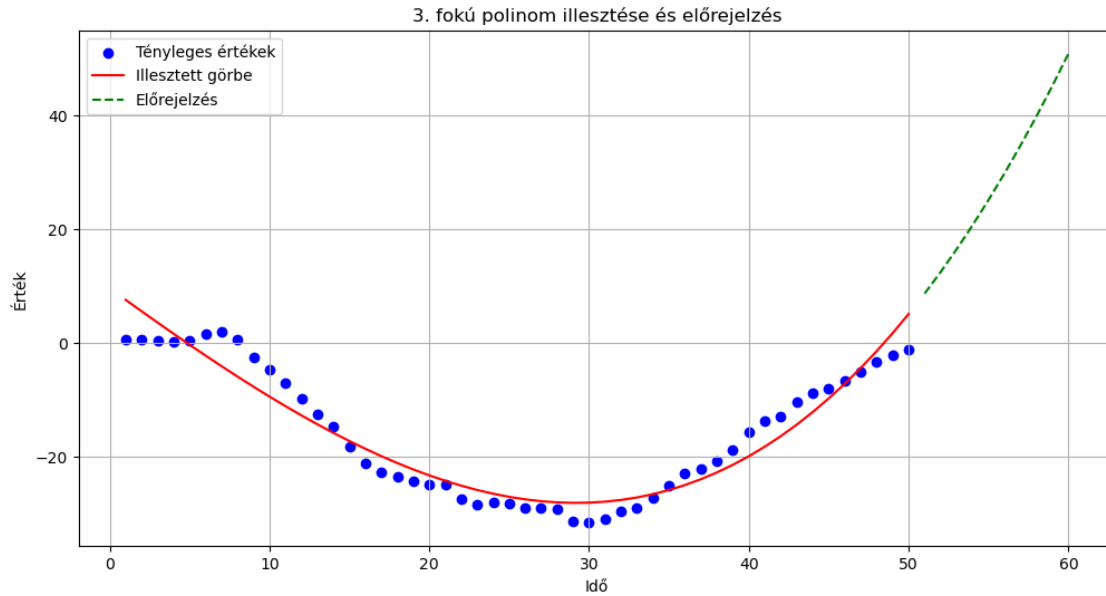
4. Homoszkedaszticitás vizsgálata (Breusch-Pagan):

Teszt statisztika: 16.254783

p-érték: 0.001005

Előrejelzések:

51. időpont: 8.67  
52. időpont: 12.46  
53. időpont: 16.46  
54. időpont: 20.69  
55. időpont: 25.14  
56. időpont: 29.81  
57. időpont: 34.72  
58. időpont: 39.86  
59. időpont: 45.24  
60. időpont: 50.86



## 1.2 Értelmezés $\epsilon = 0.05$ szignifikanciaszint mellett

### 1.2.1 Modellválasztás

Az AIC és BIC értékek alapján a 8. fokú polinom adná a legjobb illeszkedést, azonban a 3. fokú polinom mellett döntöttem az overfitting elkerülése végett.

### 1.2.2 Várható érték vizsgálata

$$H_0: E(\epsilon) = 0$$

$$H_1: E(\epsilon) \neq 0$$

t-statisztika értéke: 0.0000

p-érték: 0.9999

Döntés:  $0.9999 > 0.05$ , tehát nem vetjük el  $H_0$ -t

### 1.2.3 Normalitás vizsgálata (Shapiro-Wilk teszt)

$H_0$ : A hibatagok normális eloszlásúak

$H_1$ : A hibatagok nem normális eloszlásúak

Teszt statisztika: 0.9711

p-érték: 0.2557

Döntés:  $0.2557 > 0.05$ , tehát nem vetjük el  $H_0$ -t

### 1.2.4 Függetlenség vizsgálata (Ljung-Box teszt)

$H_0$ : A hibatagok függetlenek

$H_1$ : A hibatagok autokorreláltak

A teszt minden vizsgált késleltetésre (1-10 lag) erősen szignifikáns autokorrelációt mutat

Döntés: Minden késleltetésre  $p < 0.05$ , tehát elvetjük  $H_0$ -t

### 1.2.5 Homoszkedaszticitás vizsgálata (Breusch-Pagan teszt)

$H_0$ : A hibatagok homoszkedasztikusak

$H_1$ : A hibatagok heteroszkedasztikusak

Teszt statisztika: 16.2548

p-érték: 0.0010

Döntés:  $0.0010 < 0.05$ , tehát elvetjük  $H_0$ -t

### 1.2.6 Összefoglaló értékelés

A hibatagok diagnosztikai vizsgálata alapján:

- A várható érték feltétel teljesül (az átlag gyakorlatilag 0).
- A normalitás feltétele teljesül (a hibatagok normális eloszlásúak).
- A függetlenség feltétele nem teljesül, erős pozitív autokorreláció van jelen.
- A homoszkedaszticitás feltétele nem teljesül, a hibatagok heteroszkedasztikusak.

## 2 Exponenciális simítás alkalmazása

### 2.1 Kód és eredmények

```
# Exponenciális simítás (optimális alpha meghatározása)
model = SimpleExpSmoothing(df['Érték']).fit()
alpha = model.model.params['smoothing_level']

# Illesztett értékek és előrejelzések
fitted_values = model.fittedvalues
forecast = model.forecast(5)

# Illeszkedés vizsgálata
mae = mean_absolute_error(df['Érték'], fitted_values)
mse = mean_squared_error(df['Érték'], fitted_values)
rmse = np.sqrt(mse)

# Reziduálisok vizsgálata
residuals = model.resid

# 1. Várható érték vizsgálata
resid_mean = np.mean(residuals)
resid_std = np.std(residuals, ddof=1)
t_stat = resid_mean / (resid_std / np.sqrt(len(residuals)))
p_value_mean = 2 * stats.t.cdf(-abs(t_stat), len(residuals) - 1)

# 2. Normalitás vizsgálata (Shapiro-Wilk teszt)
shapiro_stat, shapiro_p = stats.shapiro(residuals)

# 3. Függetlenség vizsgálata (Ljung-Box teszt)
lb_stat = sm.stats.diagnostic.acorr_ljungbox(residuals)
```

```

# 4. Homoszkedaszticitás vizsgálata (Breusch-Pagan teszt)
exog = sm.add_constant(fitted_values)
bp_test = sm.stats.diagnostic.het_breuschpagan(residuals, exog)

# Eredmények kiírása
print("\nIlleszkedési mutatók:")
print(f"MAE = {mae:.4f}")
print(f"MSE = {mse:.4f}")
print(f"RMSE = {rmse:.4f}")
print(f"Smoothing level (alpha) = {alpha:.4f}")

print("\nHibatagok vizsgálata - eredmények:")
print("-" * 50)
print("1. Várható érték vizsgálata:")
print(f"Átlag: {resid_mean:.6f}")
print(f"t-statisztika: {t_stat:.6f}")
print(f"p-érték: {p_value_mean:.6f}")

print("\n2. Normalitás vizsgálata (Shapiro-Wilk):")
print(f"Teszt statisztika: {shapiro_stat:.6f}")
print(f"p-érték: {shapiro_p:.6f}")

print(f"\n3. Függetlenség vizsgálata (Ljung-Box):")
print("Lag  Teszt statisztika  p-érték")
print("-" * 35)
for lag, row in lb_stat.iterrows():
    print(f"{lag:2d}    {row['lb_stat']:.14.6f}    {row['lb_pvalue']:.6e}")

print("\n4. Homoszkedaszticitás vizsgálata (Breusch-Pagan teszt):")
print(f"Teszt statisztika: {bp_test[0]:.6f}")
print(f"p-érték: {bp_test[1]:.6f}")

print("\nElőrejelzések:")
for i, pred in enumerate(forecast, 1):
    print(f"{len(df) + i}. időpont: {pred:.2f}")

# Ábrázolás
plt.figure(figsize=(12, 6))
plt.scatter(df['Idő'], df['Érték'], color='blue', label='Eredeti adatok')
plt.plot(df['Idő'], fitted_values, 'r-', label=f'Simított ( $\alpha={alpha:.4f}$ )')

future_points = np.arange(len(df), len(df) + len(forecast))
plt.plot(future_points, forecast, 'g--', label='Előrejelzés')

plt.title('Exponenciális simítás és előrejelzés')
plt.xlabel('Idő')
plt.ylabel('Érték')

```



```
plt.legend()  
plt.grid(True)  
plt.show()
```

Illeszkedési mutatók:

MAE = 1.3446

MSE = 2.7510

RMSE = 1.6586

Smoothing level (alpha) = 1.0000

Hibatagok vizsgálata - eredmények:

-----  
1. Várható érték vizsgálata:

Átlag: -0.035400

t-statisztika: -0.149436

p-érték: 0.881823

2. Normalitás vizsgálata (Shapiro-Wilk):

Teszt statisztika: 0.961779

p-érték: 0.105540

3. Függetlenség vizsgálata (Ljung-Box):

Lag    Teszt statisztika    p-érték

-----  
1        34.645889    3.954729e-09  
2        59.005126    1.538862e-13  
3        82.658607    8.253867e-18  
4        104.418817    1.126498e-21  
5        118.862058    5.466764e-24  
6        131.665637    5.730822e-26  
7        144.778551    5.062839e-28  
8        151.797860    8.266950e-29  
9        155.033991    7.976957e-29  
10       156.828963    1.461608e-28

4. Homoszkedaszticitás vizsgálata (Breusch-Pagan teszt):

Teszt statisztika: 0.487821

p-érték: 0.484901

Előrejelzések:


51. időpont: -1.25

52. időpont: -1.25

53. időpont: -1.25

54. időpont: -1.25

55. időpont: -1.25



## 2.2 Exponenciális simítás eredményei

### 2.2.1 Modell specifikációk

A modellben a SimpleExpSmoothing függvény által meghatározott  $\alpha = 1.0000$  simítási paramétert használtuk.

### 2.2.2 Illeszkedési mutatók

MAE (Mean Absolute Error): 1.3446

Az átlagos abszolút hiba azt mutatja, hogy az előrejelzéseink átlagosan 1.3446 egységgel térnek el a tényleges értékektől.

MSE (Mean Squared Error): 2.7510

Az átlagos négyzetes hiba az előrejelzési hibák négyzetének átlaga, jelen esetben 2.7510. Ez a mutató érzékeny a nagyobb eltérésekre, mivel a hibákat négyzetre emeli.

RMSE (Root Mean Squared Error): 1.6586

A négyzetes átlaggyök hiba az MSE négyzetgyöke, ami az előrejelzési hibák átlagos nagyságát adja meg az eredeti mértékegységben.

Simítási paraméter (alpha): 1.0000

Az alpha értéke 1.0, ami azt jelenti, hogy a modell teljes mértékben az utolsó megfigyelésre támaszkodik az előrejelzés során. Ebben az esetben a modell nem simítja az adatokat, hanem minden előrejelzés az utolsó ismert érték lesz.

## 2.3 Hibatagok tulajdonságainak vizsgálata $\epsilon = 0.05$ szignifikanciaszint mellett

### 2.3.1 Várható érték vizsgálata

$H_0$ :  $E(\epsilon) = 0$

$H_1$ :  $E(\epsilon) \neq 0$

t-statisztika értéke: -0.1494

p-érték: 0.8818

Döntés:  $0.8818 > 0.05$ , tehát nem vetjük el  $H_0$ -t

### 2.3.2 Normalitás vizsgálata (Shapiro-Wilk teszt)

$H_0$ : A hibatagok normális eloszlásúak

$H_1$ : A hibatagok nem normális eloszlásúak

Teszt statisztika: 0.9618

p-érték: 0.1055

Döntés:  $0.1055 > 0.05$ , tehát nem vetjük el  $H_0$ -t

### 2.3.3 Függetlenség vizsgálata (Ljung-Box teszt)

$H_0$ : A hibatagok függetlenek

$H_1$ : A hibatagok autokorreláltak

A teszt minden vizsgált késleltetésre (1-10 lag) erősen szignifikáns autokorrelációt mutat

Döntés: Minden késleltetésre  $p < 0.05$ , tehát elvetjük  $H_0$ -t

### 2.3.4 Homoszkedaszticitás vizsgálata (Breusch-Pagan teszt)

$H_0$ : A hibatagok homoszkedasztikusak

$H_1$ : A hibatagok heteroszkedasztikusak

Teszt statisztika: 0.4878

p-érték: 0.4849

Döntés:  $0.4849 > 0.05$ , tehát nem vetjük el  $H_0$ -t

## 2.4 Összefoglaló értékelés

A hibatagok diagnosztikai vizsgálata alapján:

- A várható érték feltétel teljesül (az átlag gyakorlatilag 0)
- A normalitás feltétele teljesül (a hibatagok normális eloszlásúak)
- A függetlenség feltétele nem teljesül, erős pozitív autokorreláció van jelen
- A homoszkedaszticitás feltétele teljesül (a szórás állandó)

## 3 Box-Jenkins modell

### 3.1 Kód és eredmények

```
# Idősor stacionaritásának vizsgálata (ADF teszt)
adf_result = adfuller(df['Érték'])
print('\nADF Teszt eredménye:')
print(f'ADF Statisztika: {adf_result[0]:.4f}')
print(f'p-érték: {adf_result[1]:.4f}')
```

```

# ACF és PACF ábrák a paraméterek meghatározásához
fig, (ax1, ax2) = plt.subplots(2, 1, figsize=(12, 8))
plot_acf(df['Érték'], ax=ax1)
plot_pacf(df['Érték'], ax=ax2)
plt.tight_layout()
plt.show()

# ARIMA modell illesztése
p, d, q = 1, 1, 1
model = ARIMA(df['Érték'], order=(p, d, q))
results = model.fit()

# Illesztett értékek és előrejelzések
fitted_values = results.fittedvalues
forecast = results.forecast(steps=5)

# Reziduálisok vizsgálata
residuals = results.resid

# 1. Várható érték vizsgálata
resid_mean = np.mean(residuals)
resid_std = np.std(residuals, ddof=1)
t_stat = resid_mean / (resid_std/np.sqrt(len(residuals)))
p_value_mean = 2 * stats.t.cdf(-abs(t_stat), len(residuals)-1)

# 2. Normalitás vizsgálata
shapiro_stat, shapiro_p = stats.shapiro(residuals)

# 3. Függetlenség vizsgálata (Ljung-Box teszt)
lb_stat = sm.stats.diagnostic.acorr_ljungbox(residuals)

# 4. Homoszkedaszticitás vizsgálata
exog = sm.add_constant(fitted_values)
bp_test = sm.stats.diagnostic.het_breuschpagan(residuals, exog)

print('\nModell eredmények:')
print(results.summary().tables[0])
print(results.summary().tables[1])

print('\nHibatagok vizsgálata:')
print(f'Várható érték teszt p-érték: {p_value_mean:.4f}')
print(f'Shapiro-Wilk teszt p-érték: {shapiro_p:.4f}')
print(f"Ljung-Box teszt:")
print("Lag Teszt statisztika p-érték")
print("-" * 35)
for lag, row in lb_stat.iterrows():

```

```


    print(f"{lag:2d}    {row['lb_stat']:14.6f}    {row['lb_pvalue']:.6e}")
print(f'\nBreusch-Pagan teszt p-érték: {bp_test[1]:.4f}')

print('\nElőrejelzések:')
for i, pred in enumerate(forecast, 1):
    print(f'{len(df) + i}. időpont: {pred:.2f}')

# Ábrázolás
plt.figure(figsize=(12, 6))
plt.plot(df['Idő'], df['Érték'], 'b.', label='Eredeti adatok')
plt.plot(df['Idő'], fitted_values, 'r-', label=f'ARIMA({p},{d},{q})')
future_points = np.arange(len(df), len(df) + 5)
plt.plot(future_points, forecast, 'g--', label='Előrejelzés')
plt.title('ARIMA modell és előrejelzés')
plt.xlabel('Idő')
plt.ylabel('Érték')
plt.legend()
plt.grid(True)
plt.show()

```

ADF Teszt eredménye:  
ADF Statisztika: -2.5644  
p-érték: 0.1006



Modell eredmények:

#### SARIMAX Results

```
=====
Dep. Variable:          Érték    No. Observations:          50
Model:                 ARIMA(1, 1, 1)  Log Likelihood          -68.798
Date:                 Wed, 04 Dec 2024  AIC              143.597
Time:                 20:18:42    BIC              149.272
Sample:                 0        HQIC              145.750
                        - 50
Covariance Type:          opg
=====
```

```
=====
                        coef    std err          z      P>|z|      [0.025      0.975]
-----
ar.L1                0.8688      0.090      9.658      0.000      0.692      1.045
ma.L1               -0.2181      0.159     -1.372      0.170     -0.530      0.094
sigma2              0.9504      0.193      4.913      0.000      0.571      1.329
=====
```

Hibatagok vizsgálata:

Várható érték teszt p-érték: 0.8523

Shapiro-Wilk teszt p-érték: 0.0627

Ljung-Box teszt:

Lag Teszt statisztika p-érték

```
-----
1          0.212220    6.450331e-01
2          3.389275    1.836658e-01
3          3.694513    2.963968e-01
4          7.022499    1.347040e-01
5          7.781213    1.687128e-01
6          7.867512    2.479714e-01
7         13.683233    5.711086e-02
8         13.708309    8.969225e-02
9         15.190585    8.583220e-02
10        16.478098    8.673992e-02
```

Breusch-Pagan teszt p-érték: 0.5577

Előrejelzések:

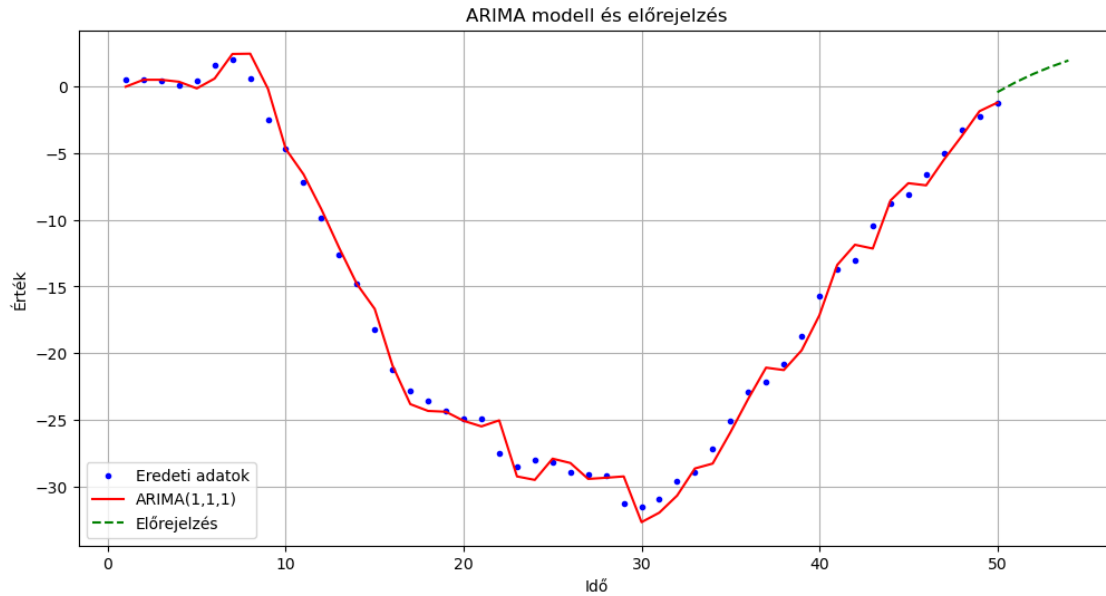
51. időpont: -0.41

52. időpont: 0.31

53. időpont: 0.94

54. időpont: 1.49

55. időpont: 1.97



## 3.2 Értelmezés $\epsilon = 0.05$ szignifikanciaszint mellett

### 3.2.1 ADF teszt eredménye

$H_0$ : Az idősor nem stacionárius

$H_1$ : Az idősor stacionárius

ADF Statisztika: -2.5644

p-érték: 0.1006

Döntés:  $0.1006 > 0.05$ , tehát nem vetjük el  $H_0$ -t, az idősor nem stacionárius, ezért szükséges differenciálnunk

### 3.2.2 Modell paraméterek

ARIMA(1,1,1) modellt illesztettünk, ahol:

- $p = 1$  (autoregresszív tag), mert a PACF ábrán az első késleltetés volt szignifikáns
- $d = 1$  (differenciálás rendje), mert az idősor nem stacionárius
- $q = 1$  (mozgóátlag tag), mert az ACF ábra az első késleltetésnél mutat szignifikáns értéket

### 3.2.3 Paraméterek szignifikanciája

- AR(1) tag: p-érték =  $0.000 < 0.05$ , szignifikáns
- MA(1) tag: p-érték =  $0.170 > 0.05$ , nem szignifikáns

### 3.2.4 Modell illeszkedési mutatók

AIC: 143.597

BIC: 149.272

Log Likelihood: -68.798

### 3.3 Hibatagok tulajdonságainak vizsgálata

#### 3.3.1 Várható érték vizsgálata

p-érték:  $0.8523 > 0.05$ , tehát nem vetjük el  $H_0$ -t

#### 3.3.2 Normalitás vizsgálata (Shapiro-Wilk teszt)

p-érték:  $0.0627 > 0.05$ , tehát nem vetjük el  $H_0$ -t

#### 3.3.3 Függetlenség vizsgálata (Ljung-Box teszt)

Minden késleltetésre  $p > 0.05$ , tehát nem vetjük el  $H_0$ -t

#### 3.3.4 Homoszkedaszticitás vizsgálata (Breusch-Pagan teszt)

p-érték:  $0.5577 > 0.05$ , tehát nem vetjük el  $H_0$ -t

### 3.4 Összefoglaló értékelés

- A modell diagnosztikája megfelelő:
  - A várható érték feltétel teljesül
  - A hibatagok normális eloszlásúak
  - A függetlenség feltétele teljesül
  - A homoszkedaszticitás feltétele teljesül
- Az AR(1) tag szignifikáns, míg az MA(1) tag nem
- Az előrejelzések növekvő trendet mutatnak